

SciGYM における 2026 年 9 月時点の最新モデル 6 種の事前登録評価: 論文 TABLE 1 と同じ条件で SMALL を測り直し、LARGE にも広げる

Anonymous authors

Paper under double-blind review

ABSTRACT

SciGym (Duan et al., 2025) は、反応をすべて取り除いた SBML モデルを LLM エージェントに渡し、摂動実験とコード実行を繰り返して反応機構を復元させるベンチマークである。論文の Table 1 は 2025 年春の 3 社のフロンティアモデル 6 つを SciGym-small 137 件で各 1 回走らせた平均値を報告している。本研究は、公開コードの Controller と評価器をそのまま用い、論文と同じ条件 (137 件、最大 20 反復、temperature 1.0) で、2026 年 9 月時点で Vercel AI Gateway から利用できる各社の最新モデル 6 種 (OpenAI の gpt-6-sol と gpt-6-luna、Anthropic の claude-opus-5.5 と claude-sonnet-5、Google の gemini-3.1-pro-preview と gemini-3.8-flash) を評価し、論文の Table 1 をそのまま並べて報告する。あわせて、論文が評価していない large split 213 件も同じ条件で走らせる。実験前に、small と large のそれぞれで 6 モデルすべての平均 Simulation Trajectory Error (STE) が論文 Table 1 の最良行 (Gemini-2.5-Pro の 0.3212) 以下であることを反証線として登録する。Reaction Matching Score (RMS) と Network Topology Score (NTS) は同じ実行から表として報告する。結果: small では 6 モデルすべてが論文最良行を下回り (仮説 1 は全主張が支持)、gpt-6-sol と claude-opus-5.5 の STE は 0.05~0.07 と論文最良の 7 分の 1 から 5 分の 1 に達した。large ではこの 2 モデルだけが論文最良行の水準を保ち、他の 4 モデルは上回った (仮説 2 は 2 主張が支持、4 主張が反証)。claude-opus-5.5 の応答拒否、large での文脈超過、ODE ソルバー内での停止という 3 つの系統的な要因を件数とともに報告する。

1 はじめに

LLM に科学的発見のサイクル全体 (実験の設計、結果の解析、機構の提案) を行わせて測るベンチマークとして、SciGym (Duan et al., 2025) が提案された。BioModels 由来の SBML モデルから反応をすべて取り除いたものをエージェントに渡し、エージェントは初期濃度を変えた摂動実験を要求し、返ってきた時系列を Python で解析し、最終的な SBML を提出する。提出モデルは真のモデルと、軌道誤差 (STE) と反応の一致度 (RMS) で比較される。

論文の主結果である Table 1 は、3 社の pro / mini 計 6 モデルを SciGym-small の 137 件で評価した平均値である (Duan et al., 2025, s1.p2, s1.p10)。評価されたのは 2025 年春の版 (Claude-3.7-Sonnet と 3.5-Haiku、Gemini-2.5-Pro と Flash のプレビュー版、GPT-4.1 と 4.1-mini) である (Duan et al., 2025, s1.p1)。その後 1 年半で各社のモデルは数世代進んだが、同じ閉ループの課題がどこまで解けるようになったかは示されていない。

AIRAS の先行研究は、現行 API の Gemini-2.5-Pro で同じ課題を解かせたときの平均 STE が論文の 0.3212 から 0.05 以内に収まるかを事前登録して検証し (auto-res2/scigym-table1-reproduction, AIRAS, s3.p1)、また open-weight モデル 6 種が論文の GPT-4.1-mini の水準 (0.6007) に届くかを同じプロトコルで評価した (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p1)。後者では kimi-k2.6 の平均 STE が 0.2100 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p2)、kimi-k3 が 0.2251 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p3) と、論文 Table 1 の最良行 Gemini-2.5-Pro の 0.3212 (Duan et al., 2025, s1.p5) を下回った。本研究は同じ Controller、同じ条件で 2026 年 9 月時点の各社最新 6 モデルを走ら

せ、論文の Table 1 をそのまま並べて世代の差を報告する。論文が計算資源の制約から評価しなかった large split 213 件 (Duan et al., 2025, s1.p2) にも同じ設定で広げる。

判定は AIRAS の事前登録の枠組みに従い、仮説・判定基準・予測区間・実行条件を実験前に記録へ凍結し、実験後は計測値だけを流し込む。

2 関連研究

SciGym (Duan et al., 2025) は、単一スキルを測る既存のベンチマークと異なり、エージェントが自ら摂動実験を設計してその結果を受け取る閉ループを評価する。評価指標は 3 つで、種間の相互作用の F1 (NTS)、反応物と生成物の集合が一致した反応の適合率・再現率・F1 (RMS, modifier まで要求する厳格版もある) (Duan et al., 2025, s1.p8)、および全種の時系列の対称平均絶対パーセント誤差 (STE) (Duan et al., 2025, s1.p9) である。論文は pro モデルが mini モデルを一貫して上回り (Duan et al., 2025, s1.p6)、Gemini-Pro が最良であった (Duan et al., 2025, s1.p7) と報告している。

先行する Table 1 の再現では、現行 API の GPT-4.1 と 4.1-mini、Gemini-2.5-Flash は論文値の 0.05 以内に収まったが、Gemini-2.5-Pro は 0.4148 (auto-res2/scigym-table1-reproduction, AIRAS, s3.p2) と論文値を再現しなかった。open-weight モデルの評価では kimi-k2.6 が 0.2100 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p2)、kimi-k3 が 0.2251 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p3)、deepseek-v4.1-flash が 0.2405 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p4) に達した。

3 仮説と予測

以下は記録 (record.json) から生成された仮説・主張・判定基準・予測区間の一覧である。実験後は Observed と Verdict が計測値から埋められる。

Hypothesis 1. 2026 年 9 月時点で Vercel AI Gateway から利用できる各社の最新モデル 6 種 (OpenAI の gpt-6-sol と gpt-6-luna、Anthropic の claude-opus-5.5 と claude-sonnet-5、Google の gemini-3.1-pro-preview と gemini-3.8-flash) は、SciGym 公開コードの Controller をそのまま用いて論文と同じ条件 (SciGym-small 137 件、最大 20 反復、temperature 1.0) で解かせたとき、いずれも平均 Simulation Trajectory Error (STE) が論文 Table 1 の最良行 (Gemini-2.5-Pro の 0.3212) 以下である。 (Duan et al., 2025, s1.p1, s1.p5, s1.p10), (auto-res2/scigym-table1-reproduction, AIRAS, s3.p2), (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p2)

Claim 1 gpt-6-sol (openai/gpt-6-sol) で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p2), (h4duan, 2025, s2.p1) *Rationale:* OpenAI の現行世代の推論モデルが論文の最良行に届けば、h1 の gpt-6-sol の部分を担う。 *Criterion:* $\text{gpt-6-sol.trajectory_smape} - 0.3212 \leq 0$. *Prediction:* $[-0.2, 0]$ (open-weight の kimi-k2.6 / kimi-k3 / deepseek-v4.1-flash が同条件で 0.21~0.24 に達した (s4.p2~s4.p4)。商用の最新モデルはそれと同等かそれ以上を予測する)。 *Observed:* -0.274004. *Verdict:* supported.

Claim 2 gpt-6-luna (openai/gpt-6-luna) で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p5), (h4duan, 2025, s2.p1) *Rationale:* OpenAI の最小クラスのモデルが論文の最良行に届けば、h1 の gpt-6-luna の部分を担う。 *Criterion:* $\text{gpt-6-luna.trajectory_smape} - 0.3212 \leq 0$. *Prediction:* $[-0.15, 0.05]$ (open-weight の 27B~35B 級 (qwen3.8-27b 0.25, qwen3.6-35b 0.46) が同条件で最良行の前後に分かれた (s4.p5, s4.p6)。最小クラスの商用モデルはその中間を予測する)。 *Observed:* -0.0917086. *Verdict:* supported.

Claim 3 claude-opus-5.5 (anthropic/claude-opus-5.5) で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p3), (h4duan, 2025, s2.p1) *Rationale:* Anthropic

の現行の上位モデルが論文の最良行に届けば、h1 の claude-opus-5.5 の部分を担う。*Criterion:* `claude-opus-5.5.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.2, 0] (c1 と同じ (s4.p2~s4.p4)). *Observed:* -0.255497. *Verdict:* supported.

- Claim 4** claude-sonnet-5 (anthropic/claude-sonnet-5) で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (auto-res2/scigym-rikyu-open-models , AIRAS, s4.p4), (h4duan, 2025, s2.p1) *Rationale:* Anthropic の中位モデルが論文の最良行に届けば、h1 の claude-sonnet-5 の部分を担う。*Criterion:* `claude-sonnet-5.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.2, 0] (中位の商用モデルは open-weight の上位 (0.21~0.25) に近いと予測する (s4.p2~s4.p5)). *Observed:* -0.0680545. *Verdict:* supported.
- Claim 5** gemini-3.1-pro-preview (google/gemini-3.1-pro-preview) で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p7, s1.p10), (auto-res2/scigym-table1-reproduction , AIRAS, s3.p2), (h4duan, 2025, s2.p1) *Rationale:* 論文で最良だった Gemini Pro 系の現行版が自らの旧版の値に届けば、h1 の gemini-3.1-pro-preview の部分を担う。*Criterion:* `gemini-3.1-pro.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.2, 0] (c1 と同じ。なお現行 API の gemini-2.5-pro の再実行は 0.4148 で論文値を再現しなかった (s3.p2) ため、旧版との差は環境差を含む)。 *Observed:* -0.0775416. *Verdict:* supported.
- Claim 6** gemini-3.8-flash (google/gemini-3.8-flash) で SciGym-small 137 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5, s1.p10), (auto-res2/scigym-table1-reproduction , AIRAS, s3.p3), (h4duan, 2025, s2.p1) *Rationale:* Gemini Flash 系の現行版が論文の最良行に届けば、h1 の gemini-3.8-flash の部分を担う。*Criterion:* `gemini-3.8-flash.trajectory_smape` - 0.3212 $\leq$ 0. *Prediction:* [-0.15, 0.05] (c2 と同じ。現行 API の gemini-2.5-flash の再実行は 0.4465 だった (s3.p3) が、世代が進んだ分を見込む)。 *Observed:* -0.103458. *Verdict:* supported.

Assumed, so that the claims together imply Hypothesis 1:

- temperature 1.0 での 1 回実行の平均 STE (137 件平均) の実行間変動が判定に対して十分小さいこと。先行する Table 1 再現では件ごとの STE の標準偏差はおおよそ 0.27、137 件平均の標準誤差はおおよそ 0.02 であった (c1~c6)
- Vercel AI Gateway 経由の各モデルが、提供元の API から直接呼んだ場合と同じ能力で応答すること。reasoning の強さは各モデルの既定値のまま変えない (c1~c6)
- 論文の 6 モデルは 2025 年春の版であり、本研究の 6 モデルは 2026 年 9 月時点の各社の最新版であること。世代の差を測るのが目的なので、同名モデルの再現は求めない (c1~c6)
- aarch64 向けの libroadrunner 2.7.0 と antimony 2.14.0 が、論文環境の libroadrunner 2.8.0 と同じ軌道と評価値を与えること (c1~c6)
- 平均 STE が「論文の最良行に届くか」を代表すること。RMS (modifier あり / なし) と NTS は同じ実行から表として報告するが、判定基準には用いない (c1~c6)
- ゲートウェイの予算超過 (HTTP 402) で run が途中で止まらないこと。止まった場合はその run を最初からやり直す (c1~c6)

Hypothesis 2. 同じ 6 モデル (gpt-6-sol、gpt-6-luna、claude-opus-5.5、claude-sonnet-5、gemini-3.1-pro-preview、gemini-3.8-flash) は、同じ Controller と条件 (最大 20 反復、temperature 1.0) で、論文が評価していないより大きな系からなる SciGym-large 213 件を解かせたときも、いずれも平均 STE が論文 Table 1 (SciGym-small) の最良行 Gemini-2.5-Pro の 0.3212 以下になる。 (Duan et al., 2025, s1.p2, s1.p5, s1.p10), (auto-res2/scigym-rikyu-open-models , AIRAS, s4.p2)

- Claim 7** gpt-6-sol (openai/gpt-6-sol) で SciGym-large 213 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。 (Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models , AIRAS, s4.p2), (h4duan, 2025, s2.p1) *Rationale:* small での水準をよ

り大きな系でも保てば、h2 の gpt-6-sol の部分を担う。 *Criterion*: `gpt-6-sol-large.trajectory_smape - 0.3212 ≤ 0`. *Prediction*: $[-0.1, 0.1]$ (small での予測 (open-weight の上位が 0.21~0.24、s4.p2~s4.p4) に、系が大きくなる分の悪化を見込む。先行値が無く幅を広く取る)。 *Observed*: -0.10363. *Verdict*: supported.

Claim 8 gpt-6-luna (openai/gpt-6-luna) で SciGym-large 213 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p5), (h4duan, 2025, s2.p1) *Rationale*: c7 と同じ。h2 の gpt-6-luna の部分を担う。 *Criterion*: `gpt-6-luna-large.trajectory_smape - 0.3212 ≤ 0`. *Prediction*: $[-0.05, 0.15]$ (最小クラスのモデルは small でも基準の前後と予測しており、large では上回る可能性が高い (s4.p5、s4.p6))。 *Observed*: 0.0342854. *Verdict*: refuted.

Claim 9 claude-opus-5.5 (anthropic/claude-opus-5.5) で SciGym-large 213 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p3), (h4duan, 2025, s2.p1) *Rationale*: c7 と同じ。h2 の claude-opus-5.5 の部分を担う。 *Criterion*: `claude-opus-5.5-large.trajectory_smape - 0.3212 ≤ 0`. *Prediction*: $[-0.1, 0.1]$ (c7 と同じ)。 *Observed*: -0.159197. *Verdict*: supported.

Claim 10 claude-sonnet-5 (anthropic/claude-sonnet-5) で SciGym-large 213 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p4), (h4duan, 2025, s2.p1) *Rationale*: c7 と同じ。h2 の claude-sonnet-5 の部分を担う。 *Criterion*: `claude-sonnet-5-large.trajectory_smape - 0.3212 ≤ 0`. *Prediction*: $[-0.1, 0.1]$ (c7 と同じ)。 *Observed*: 0.114828. *Verdict*: refuted.

Claim 11 gemini-3.1-pro-preview (google/gemini-3.1-pro-preview) で SciGym-large 213 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-table1-reproduction, AIRAS, s3.p2), (h4duan, 2025, s2.p1) *Rationale*: c7 と同じ。h2 の gemini-3.1-pro-preview の部分を担う。 *Criterion*: `gemini-3.1-pro-large.trajectory_smape - 0.3212 ≤ 0`. *Prediction*: $[-0.1, 0.1]$ (c7 と同じ)。 *Observed*: 0.159937. *Verdict*: refuted.

Claim 12 gemini-3.8-flash (google/gemini-3.8-flash) で SciGym-large 213 件を最大 20 反復で解かせたときの平均 STE は、論文 Table 1 の最良行 (Gemini-2.5-Pro) の 0.3212 以下である。(Duan et al., 2025, s1.p2, s1.p3, s1.p4, s1.p5), (auto-res2/scigym-table1-reproduction, AIRAS, s3.p3), (h4duan, 2025, s2.p1) *Rationale*: c7 と同じ。h2 の gemini-3.8-flash の部分を担う。 *Criterion*: `gemini-3.8-flash-large.trajectory_smape - 0.3212 ≤ 0`. *Prediction*: $[-0.05, 0.15]$ (c8 と同じ (s3.p3))。 *Observed*: 0.0474597. *Verdict*: refuted.

Assumed, so that the claims together imply Hypothesis 2:

- large split には論文の公表値が無いので、論文の small での最良値を絶対水準の基準とする。small との難易度の差は表で並べて示すが、判定には用いない (c7~c12)
- 213 件平均の実行間変動が判定に対して十分小さいこと。件ごとの標準偏差を 0.27 とすれば平均の標準誤差はおおよそ 0.02 (c7~c12)
- 評価層 scigym_large (airas-eval v0.13.0) が公式リリースの large split 213 件を sha256 で固定し、small と同じ公式 Evaluator で採点すること (c7~c12)
- 文脈長や時間切れで提出に至らなかった件は不完全モデルの採点値で平均に含める。ゲートウェイのモデルは文脈長が 400k トークン以上あり、20 反復では超えないと見る (c7~c12)

判定基準と予測区間の根拠。 仮説 1 (small) の各主張の反証線は「(当該モデルの平均 STE) - 0.3212 ≤ 0」である。0.3212 は論文 Table 1 の最良行 Gemini-2.5-Pro の STE (Duan et al., 2025, s1.p5) であり、6 行すべてに同じ基準を置く。1 年半後の各社の最新モデル

が、論文時点の最良に届くかどうかを問う。仮説 2 (large) も同じ基準を置く。large には論文の公表値が無いので、small での最良行を絶対水準の基準とし、予測区間は上位モデルで $[-0.10, 0.10]$ 、最小クラスで $[-0.05, 0.15]$ と幅を広く取る。予測区間は上位モデル (gpt-6-sol、claude-opus-5.5、claude-sonnet-5、gemini-3.1-pro-preview) で $[-0.20, 0]$ 、最小クラス (gpt-6-luna、gemini-3.8-flash) で $[-0.15, 0.05]$ とする。根拠は open-weight の上位モデルが同条件で kimi-k2.6 0.2100 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p2)、kimi-k3 0.2251 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p3)、deepseek-v4.1-flash 0.2405 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p4) に達したことと、27B~35B 級が 0.25 と 0.46 に分かれたこと (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p5, s4.p6) である。1 件の STE の標準偏差を 0.27 程度と見積もると 137 件平均の標準誤差は約 0.02 で、差が 0.02 未満のときは結論が揺らぎうることを前提として記録する。

RMS (modifier あり / なし) と NTS も同じ実行から表として報告するが、1 つの主張に置ける判定基準は 1 つであるため、判定には用いない。各社の上位と下位の差、small と large の難易度差も表で示すにとどめ、主張にはしない。

4 方法

タスク. 各インスタンスは真の SBML (truth.xml)、反応を取り除いた不完全な SBML (partial.xml)、シミュレーション条件 (truth.sedml) からなる。エージェントは不完全な SBML を受け取り、各ターンで実験 (初期濃度の変更を指定し、真のモデルの時系列を得る)、コード実行 (numpy / pandas / scipy / libsbml と、仮説モデルを走らせる simulate 関数が使える)、提出のいずれかを markdown 形式で返す。提出は任意の時点で行え、反復数の上限は 20 である (Duan et al., 2025, s1.p3)。提出した SBML が無効な場合は追加のデバッグ反復が許され、それでも無効なら不完全 SBML のまま採点される (Duan et al., 2025, s1.p4)。

実行系. ループ、プロンプト、実験の実行はすべて公開コード (h4duan, 2025) の Controller をそのまま用いる。本研究が書くのは、(1) OpenAI 互換 API でモデルを呼ぶ LLM 実装 (公式の GPT 実装と同じく、システムプロンプトと全履歴を毎回送る)、(2) インスタンスごとに 1 プロセスで Controller を起動し、137 件を並列に走らせる駆動部、(3) 各インスタンスの提出モデルと公式データを評価層の入力ファイルに書き出す部分だけである。公式コードでは履歴がクラス属性として定義されており 1 プロセスで複数件を走らせると履歴が持ち越されるが、1 件 1 プロセスとすることでこの問題を避ける。

指標. 採点は評価層 airas-eval のベンチマークパック scigym_small (137 件) と scigym_large (213 件) が行う。パックは公式リリースの各件 (truth / partial / sedml) を sha256 で固定し、公開コードの Evaluator (コミット 88a7b93) で提出モデルを採点して、STE (trajectory_smap)、RMS の適合率・再現率・F1 (modifier なし reaction_*, あり reaction_*_with_modifiers)、NTS の F1 (topology_f1) を件の単純平均で返す。提出 SBML が無い、または無効な件は、公式評価どおり不完全 SBML の採点値で平均に含める。

5 実験設計

モデル. Vercel AI Gateway (OpenAI 互換) 経由で、2026 年 9 月時点の各社の最新モデルを上位と下位の 2 つずつ用いる: openai/gpt-6-sol と openai/gpt-6-luna、anthropic/claude-opus-5.5 と anthropic/claude-sonnet-5、google/gemini-3.1-pro-preview と google/gemini-3.8-flash。論文の pro / mini の構図に対応させるが、各社の製品構成に厳密な対応は無く、料金と提供元の位置づけから選んだ。reasoning の強さは各モデルの既定値のまま変えない。

データ. SciGym の公式リリース (Hugging Face h4duan/scigym-sbml) のうち、論文が評価対象とした small split 137 件 (Duan et al., 2025, s1.p2) に加え、論文では評価されていない large split 213 件を用いる (いずれも RIKYU 上のコピー)。large の真のモデルの SBML は small のおよそ 3.5 倍長い。評価層は各件の内容を公式リリースの sha256 と照合する。1 run は 1 モデル × 1 split で、計 12 run である。

設定. max_iterations は論文どおり 20 (Duan et al., 2025, s1.p3) (公開 config の既定値は 5 (h4duan, 2025, s2.p2))、eval_debug_rounds は論文本文の 3 (Duan et al., 2025, s1.p4) (公

Table 1: SciGym-small 137 件における最新モデル 6 種の平均 STE (低いほど良い)、論文 Table 1 の最良行 (Gemini-2.5-Pro, 0.3212) との差、Reaction Matching Score の適合率 / 再現率 / F1 (modifier なし・あり、高いほど良い)、有効な提出件数。

	STE ↓	Δ vs Gemini-2.5-Pro	P	R	F1	P _m	R _m	F1 _m	n _{valid}
gpt-6-sol	0.047	-0.274	0.584	0.625	0.593	0.385	0.392	0.382	137
gpt-6-luna	0.229	-0.092	0.372	0.365	0.359	0.240	0.219	0.222	137
claude-opus-5.5	0.066	-0.255	0.674	0.666	0.659	0.461	0.455	0.451	137
claude-sonnet-5	0.253	-0.068	0.463	0.447	0.448	0.288	0.267	0.272	137
gemini-3.1-pro-preview	0.244	-0.078	0.580	0.558	0.556	0.358	0.335	0.339	137
gemini-3.8-flash	0.218	-0.103	0.746	0.724	0.723	0.507	0.487	0.488	137

Table 2: SciGym-large 213 件における最新モデル 6 種の平均 STE (低いほど良い)、論文 Table 1 の最良行 (Gemini-2.5-Pro, 0.3212) との差、Reaction Matching Score の適合率 / 再現率 / F1 (modifier なし・あり)、有効な提出件数。

	STE ↓	Δ vs Gemini-2.5-Pro	P	R	F1	P _m	R _m	F1 _m	n _{valid}
gpt-6-sol	0.218	-0.104	0.443	0.383	0.391	0.260	0.218	0.225	209
gpt-6-luna	0.355	0.034	0.263	0.174	0.184	0.122	0.088	0.088	200
claude-opus-5.5	0.162	-0.159	0.516	0.436	0.449	0.317	0.266	0.272	211
claude-sonnet-5	0.436	0.115	0.324	0.202	0.229	0.188	0.111	0.128	213
gemini-3.1-pro-preview	0.481	0.160	0.376	0.256	0.282	0.229	0.148	0.165	212
gemini-3.8-flash	0.369	0.047	0.531	0.432	0.446	0.352	0.284	0.294	213

開 config の既定値は 5 (h4duan, 2025, s2.p3)), `temperature` は公開 config の 1.0 (h4duan, 2025, s2.p1)、摂動は初期濃度の変更のみとする。応答のトークン上限は 32768 とし、reasoning で使い切った応答は上限を倍にして呼び直す。本文が空で返った呼び出しは呼び直し、reasoning 側に本文が入っていればそれを用いる。各モデル、各インスタンスを 1 回ずつ実行する。ゲートウェイの予算超過 (HTTP 402) が起きた run は途中の件を残さず最初からやり直す。

計算資源と環境. 実行は Seyval を通じて RIKYU (Shurm, GB200 ノード、aarch64) で行い、LLM は Vercel AI Gateway を呼ぶ。GPU は使わないが、資源の単位が GPU であるため 1 GPU を要求する。環境は Dockerfile と `uv.lock` で固定する。aarch64 向けの wheel が無いため、libroadrunner は公式の 2.8.0 ではなく 2.7.0、antimony は 2.14.0 を使い、rrplugins と phrasedml は除外する。この差でシミュレーション結果がわずかに変わる可能性があり、仮説の前提として記録する。

段階. `sanity` は各 split の先頭 1 件を 2 反復で走らせて配管を確かめる。`pilot` は sorted した件から等間隔に 10 件を 20 反復で走らせ、1 件あたりの所要時間と費用を測る。主張の判定は full (small 137 件、large 213 件) の結果だけで行い、`sanity` と `pilot` の結果は記録に取り込まない。

run と主張の対応. small: `gpt-6-sol` → Claim 1, `gpt-6-luna` → Claim 2, `claude-opus-5.5` → Claim 3, `claude-sonnet-5` → Claim 4, `gemini-3.1-pro` → Claim 5, `gemini-3.8-flash` → Claim 6. large: 同じ順で `gpt-6-sol-large` → Claim 7 から `gemini-3.8-flash-large` → Claim 12。

6 結果

表 1 に small (137 件)、表 2 に large (213 件) の各 run の平均 STE、論文 Table 1 の最良行 Gemini-2.5-Pro (0.3212) (Duan et al., 2025, s1.p5) との差、RMS の適合率・再現率・F1 (modifier なし / あり)、有効な SBML が提出された件数を示す。各値は評価層 `scigym_small` / `scigym_large` のレポートから記録経由で流し込んだものである。

表 3 は、論文 Table 1 の 6 モデルの値 (Duan et al., 2025, s1.p5) と本研究の 12 run の値を同じ列構成で並べたものである。論文の値は引用としての転記で未検証の印を付け、本研究の値は記録から流し込んだものをそのまま表示している。

Table 3: 論文 Table 1 (Duan et al. (Duan et al., 2025, s1.p5)、SciGym-small 137 件、各モデル 1 回実行) と本研究の値の対比。STE は低いほど、RMS の $P \cdot R \cdot F1$ は高いほど良い。w/ は modifier あり、w/o は modifier なし。上段 6 行は論文からの転記 (未検証)、下段は本研究の記録由来の値で、有効提出は有効な SBML が提出された件数 (small は 137 件中、large は 213 件中。論文は報告していない)。

	STE ↓	w/ P	w/ R	w/ F1	w/o P	w/o R	w/o F1	有効提出
論文 Table 1 (2025 年春の 6 モデル、SciGym-small)								
Gemini-2.5-Flash	0.4181	0.1527	0.1071	0.1217	0.2399	0.1839	0.2005	—
GPT-4.1-mini	0.6007	0.1516	0.1253	0.1320	0.2530	0.2313	0.2322	—
Claude-3.5-Haiku	0.6281	0.0858	0.0421	0.0530	0.1454	0.0805	0.0987	—
Gemini-2.5-Pro	0.3212	0.2138	0.1664	0.1817	0.3781	0.3219	0.3383	—
GPT-4.1	0.4611	0.2067	0.1597	0.1740	0.3517	0.2888	0.3038	—
Claude-3.7-Sonnet	0.3615	0.1780	0.1698	0.1688	0.3160	0.3170	0.3047	—
本研究、SciGym-small 137 件 (2026 年 9 月の 6 モデル)								
gpt-6-sol	0.0471962	0.384869	0.392292	0.381622	0.584362	0.624592	0.592936	137
gpt-6-luna	0.229491	0.239597	0.219216	0.221795	0.372394	0.364651	0.359428	137
claude-opus-5.5	0.0657034	0.461131	0.455327	0.450809	0.674399	0.665673	0.659379	137
claude-sonnet-5	0.253146	0.28836	0.266875	0.271909	0.463182	0.447216	0.447958	137
gemini-3.1-pro-preview	0.243658	0.358473	0.335445	0.339429	0.580428	0.558394	0.556226	137
gemini-3.8-flash	0.217742	0.507129	0.487003	0.487778	0.745907	0.723734	0.723037	137
本研究、SciGym-large 213 件								
gpt-6-sol	0.21757	0.260499	0.21828	0.22503	0.442742	0.382559	0.390623	209
gpt-6-luna	0.355485	0.122123	0.0880511	0.0882683	0.262915	0.174341	0.184136	200
claude-opus-5.5	0.162003	0.316516	0.266061	0.272269	0.516286	0.436111	0.449084	211
claude-sonnet-5	0.436028	0.187911	0.111479	0.127916	0.323772	0.201924	0.22901	213
gemini-3.1-pro-preview	0.481137	0.229353	0.147708	0.1648	0.375726	0.25565	0.281532	212
gemini-3.8-flash	0.36866	0.35175	0.284222	0.293929	0.531173	0.432404	0.44646	213

主張の判定. 仮説 1 (small) の各主張の反証線は「(当該モデルの平均 STE) $- 0.3212 \leq 0$ 」である (第 3 節)。平均 STE は gpt-6-sol が 0.0471962、claude-opus-5.5 が 0.0657034、gemini-3.8-flash が 0.217742、gpt-6-luna が 0.229491、gemini-3.1-pro-preview が 0.243658、claude-sonnet-5 が 0.253146 で、Claim 1~6 はすべて基準を満たした。論文最良行との差は -0.27 から -0.07 で、gpt-6-sol と claude-opus-5.5 の 2 つは事前の予測区間 $[-0.20, 0]$ を下に外れた。すなわち上位 2 モデルは予測より大きく論文の最良を引き離し、先行研究の open-weight 最良である kimi-k2.6 の 0.2100 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p2) も 4 分の 1 以下の誤差である。残る 4 モデルは予測区間の内側で、論文最良行を 0.07~0.10 下回るにとどまった。

仮説 2 (large) の反証線は同じ基準を large の 213 件に置いたものである。claude-opus-5.5 の 0.162003 (Claim 9) と gpt-6-sol の 0.21757 (Claim 7) は基準を満たし、予測区間 $[-0.10, 0.10]$ を下に外れた。一方、gpt-6-luna の 0.355485 (Claim 8)、claude-sonnet-5 の 0.436028 (Claim 10)、gemini-3.1-pro-preview の 0.481137 (Claim 11)、gemini-3.8-flash の 0.36866 (Claim 12) は基準を上回り、反証された。claude-sonnet-5 と gemini-3.1-pro-preview は予測区間の上限 0.10 も超えた。仮説 2 は 6 主張のうち 2 つが支持、4 つが反証で、全体としては成り立たない。

RMS と NTS. modifier なしの RMS F1 は、small では gemini-3.8-flash が 0.723037 で最も高く、claude-opus-5.5 0.659379、gpt-6-sol 0.592936、gemini-3.1-pro-preview 0.556226、claude-sonnet-5 0.447958、gpt-6-luna 0.359428 と続く。論文 Table 1 の最良 0.3383 (Duan et al., 2025, s1.p5) を 6 モデルすべてが上回り、modifier ありの厳格版 (Duan et al., 2025, s1.p8) でも論文最良の 0.1817 を全モデルが上回った。STE の順位 (gpt-6-sol < claude-opus-5.5 < gemini-3.8-flash < gpt-6-luna < gemini-3.1-pro-preview < claude-sonnet-5) と RMS F1 の順位は上位で入れ替わる。gemini-3.8-flash は反応の一致では最良だが軌道の誤差は 3 位で、gpt-6-sol は軌道が最もよく合うが反応の一致は 3 位である。すなわち、真の反応集合に近い構造を当てることと、観測される時系列を再現することは別の能力である。large では RMS F1 が claude-opus-5.5 0.449084、gemini-3.8-flash 0.44646、gpt-6-sol 0.390623 の 3 つだけが論文最良の 0.3383 を保ち、gpt-6-luna は 0.184136 まで落ちた。NTS の F1 は small で claude-opus-5.5 が 0.832303 と突出している。

完走件数とトークン. 表 4 に各 run の有効提出件数とトークン消費を示す。有効な SBML が提出された件数は small では 6 モデルとも 137 件全部で、large では gpt-6-luna の 200 件から claude-sonnet-5 と gemini-3.8-flash の 213 件までである。提出に至らなかった件は後述の文脈超過と打ち切りによる。平均反復数は claude-opus-5.5 が small で 12.7007、large で 15.6588

Table 4: 各 run の評価件数、有効な SBML が提出された件数、トークン消費。出力トークンには reasoning を含む。

	n_instances	n_valid_submissions	入力トークン	出力トークン
gpt-6-sol small	137	137	39965191	1730884
gpt-6-luna small	137	137	45675432	2488348
claude-opus-5.5 small	137	137	21943157	1890512
claude-sonnet-5 small	137	137	61802784	7815806
gemini-3.1-pro-preview small	137	137	56948180	4297865
gemini-3.8-flash small	137	137	49498289	2492963
gpt-6-sol large	213	209	202462009	3393566
gpt-6-luna large	213	200	249778504	3734138
claude-opus-5.5 large	213	211	106576311	5211836
claude-sonnet-5 large	213	213	199915458	14117390
gemini-3.1-pro-preview large	213	212	214600967	7807084
gemini-3.8-flash large	213	213	154892721	4002755

と最も少なく、137 件中 133 件を上限の 20 反復を使い切らずに自ら提出した。gpt-6-sol も small で 72 件を早期に提出している。対照的に claude-sonnet-5 と gemini-3.8-flash は large でほぼ全件が上限まで使った。入力トークンは small で 2,200 万 (claude-opus-5.5) から 6,200 万 (claude-sonnet-5)、large で 1 億 700 万から 2 億 5,000 万で、large は件数の 1.55 倍に対して 3~5 倍である。ゲートウェイの定価 (キャッシュなし) でトークン数から見積もった費用は 12 run で約 2,800 USD、最も高いのは claude-sonnet-5 large と claude-opus-5.5 large の各約 540 USD、最も安いのは gpt-6-luna small の約 6 USD である。

実行で起きたこと. 事前登録した設計からの逸脱と、実行中に判明した事実を記す。第一に、claude-opus-5.5 は一部の会話状態で応答を拒否した。ゲートウェイの応答は `finish_reason` が `content-filter`、Anthropic 側の停止理由は `refusal (category reasoning_extraction)` で、出力トークンは 0 であった。同じ会話状態では何度呼び直しても拒否されるので、その試行は失敗として件を最初からやり直した。small では 10 件で拒否が起き、やり直して全件が有効提出に至った。large では 2 件が 3 回の試行とも提出に至らず、公式規約どおり不完全モデルの採点値で平均に含めた。claude-sonnet-5 では拒否は起きなかった。gemini-3.8-flash でも Gemini 側の content filter による空応答が small と large で各 1 件あり、やり直して提出に至った。第二に、gpt-6-sol の large で 4 件、gpt-6-luna の large で 5 件が、20 反復に達する前にゲートウェイの「入力文脈長を超えた」という 400 で止まった。大きな系では反復ごとに積み上がる実験データの表が 100 万トークンの窓を超える。これらは提出なしとして平均に含めた。第三に、LLM が書いた解析コードや提出モデルの評価が ODE ソルバーの C ライブラリの中で止まり、公式 Controller の 3 分制限 (`signal.alarm`) が効かない件が large で多発した。当初は 1 試行 4 時間の上限で打ち切っていたが、実行の途中で「出力が 60 分止まった試行を打ち切る」判定を駆動部に加え、その時点で走っていた run をすべて止めて、完了済みの件を引き継いで投げ直した。この変更は Controller、プロンプト、モデルの呼び方、採点には触れておらず、引き継いだ件は変更前と同じ条件で解かれている。打ち切りの回数は gpt-6-luna large で 24、gemini-3.1-pro-preview large で 12、claude-opus-5.5 large で 9 で、3 回とも打ち切られて提出に至らなかった件は gpt-6-luna large の 9 件と claude-opus-5.5 large の 2 件である。第四に、large の評価入力 (参照 SBML と提出 SBML) が 1 run で最大 115 MB になり、記録への取り込みの上限 50 MB を超えたため、評価入力を gzip で書くように駆動部と評価層 (airas-eval 0.13.1) を変え、既に完了していた large の 4 run (gpt-6-sol、claude-opus-5.5、gpt-6-luna、gemini-3.1-pro-preview) は完了済みの件をそのまま引き継いで採点だけをやり直した。LLM の呼び出しはやり直していない。第五に、gemini-3.1-pro-preview は `finish_reason` が `error` の空応答を small で 8 回返し、いずれも呼び直して通った。これらの経緯は記録の notes にも残した。

7 考察

論文から 1 年半で、最良の STE は 7 分の 1 になった。仮説 1 の 6 主張はすべて支持され、2026 年 9 月の各社最新モデルは、論文 Table 1 が 2025 年春の 6 モデルで報告した最良の STE 0.3212 (Duan et al., 2025, s1.p5) を、同じ Controller、同じ 137 件、同じ 20 反復で全員が下

回った。上位 2 モデル (gpt-6-sol, claude-opus-5.5) の STE は 0.05~0.07 で、論文最良の 7 分の 1 から 5 分の 1、先行研究の open-weight 最良 (kimi-k2.6 の 0.2100 (auto-res2/scigym-rikyu-open-models, AIRAS, s4.p2)) の 4 分の 1 以下である。この 2 モデルは反復も使い切らず、半数以上の件で 20 反復に達する前に自ら提出している。SciGym-small はこの 2 モデルにとってほぼ飽和した課題になった。ただし比較対象は論文値の転記であり、本研究で論文の 6 モデルを再実行してはいない。先行する再現では GPT-4.1 系と Gemini-2.5-Flash は論文値の 0.05 以内に収まり、Gemini-2.5-Pro だけが 0.4148 (auto-res2/scigym-table1-reproduction, AIRAS, s3.p2) と再現しなかったのが、論文最良行の 0.3212 は当時の値としてやや楽観的である可能性があるが、0.1 を超える差はその揺らぎでは説明できない。

各社の上位と下位、そして Gemini の逆転。 OpenAI と Anthropic では上位モデルが下位モデルを STE で大きく引き離れた (gpt-6-sol 対 gpt-6-luna, claude-opus-5.5 対 claude-sonnet-5)。これは論文が報告した「pro が mini を一貫して上回る」構図 (Duan et al., 2025, s1.p6) と同じである。Google だけは逆で、gemini-3.8-flash が gemini-3.1-pro-preview を STE でも RMS でも上回った。ゲートウェイの提供モデルでは pro 系が 3.1 のプレビュー版で止まっており、flash 系は 3.8 まで世代が進んでいる。世代の差が規模の差を上回ったと読むのが自然である。先行研究の open-weight モデルでも、同じ Qwen 系で世代の新しい小型の版が古い大型の版を STE で上回っていた。名前の上での上位下位よりも、リリース時期のほうがこの課題の成績を予測する。

large は別の課題である。 論文は計算資源の制約から small だけを評価した (Duan et al., 2025, s1.p2)。本研究の large split では、6 モデルすべてで STE が 0.1~0.24 悪化し、論文最良行の水準を保てたのは claude-opus-5.5 と gpt-6-sol だけだった。反復を使い切る件が増え、早期提出は claude-opus-5.5 を除いて大きく減った。gpt-6-sol と gpt-6-luna では 100 万トークンの文脈長を超える件まで現れた。large の系は反応数も種数も多く、20 反復の中で実験を設計して機構を絞り込む余地が小さい。反復上限を 20 に固定したベンチマークの設定が、small では飽和しつつある一方で large では制約として効いている。順位は small とおおむね保たれたが、gemini-3.8-flash は large で反応の一致 (RMS) は保ったまま軌道の誤差が大きく悪化しており、構造を当てても速度定数が合わない系が増えたことを示す。

Claude の拒否は評価上の系統的な要因である。 claude-opus-5.5 の拒否は、SciGym のプロンプトが思考過程を決まった markdown 節で書かせる形式であることに反応した分類器 (reasoning extraction) によるものと考えられる。同じ会話状態では再現するが、件を最初からやり直すと別の経路をたどって通ることが多く、small では全件が提出に至った。それでも large では 2 件が提出に至らず、STE を系統的に悪くする方向に働いた。エージェント型のベンチマークで Claude 系を評価するときは、この拒否の件数を報告し、やり直しの規則を事前に決めておく必要がある。claude-sonnet-5 で拒否が起きなかったことから、モデルごとに分類器の閾値が異なる可能性がある。

公式実装の時間制限は C ライブラリの中では効かない。 本研究で最も時間を費やしたのは、モデルの能力ではなく打ち切りの設計であった。公式 Controller はコード実行を `signal.alarm` で 3 分に制限するが、シグナルは Python のバイトコード境界でしか処理されないため、`scipy` や `libroadrunner` の中で止まった計算は打ち切れない。large では 1 run あたり 10~24 件がこの状態になり、4 時間の上限まで待つ設計では run が 24 時間の枠に収まらなかった。出力の停止を外から検出して打ち切る規則を加えることで解決したが、これは公式コードの外側の措置であり、公式の 3 分制限どおりにエージェントに「時間切れ」を返してはいない。ベンチマークの規約を実装どおりに機能させるには、コード実行を別プロセスに委ねて外から止める実装が必要である。

8 結論

SciGym 公開コードの Controller を論文と同じ条件で用い、2026 年 9 月時点の各社最新モデル 6 種を SciGym-small 137 件と large 213 件で評価した。small では 6 モデルすべての平均 STE が論文 Table 1 の最良行 0.3212 を下回り (仮説 1 は全主張が支持)、gpt-6-sol と claude-opus-5.5 は 0.05~0.07 と論文最良の 7 分の 1 から 5 分の 1 に達した。large ではこの 2 モデルだけが論文最良行の水準を保ち、他の 4 モデルは上回った (仮説 2 は 2 主張が支持、4 主張が反証)。RMS でも 6 モデルが small で論文最良を上回った。実行では claude-opus-5.5 の拒否、large での文脈超過、ODE ソルバー内での停止という 3 つの系統的な要因が現れ、

いずれも件数とともに本文と記録に残した。記録は追記式なので、同じ主張に別の実行結果を後から足すことができる。

データの利用可能性

記録は record.json にある。実験コード、環境の固定 (Dockerfile と uv.lock)、各 run の結果と provenance は同じリポジトリに含まれる。

REFERENCES

auto-res2/scigym-rikyu-open-models (AIRAS). Scigym-small における open-weight モデルの事前登録評価: Rikyu の推論 api で提供される 8 モデルは論文の gpt-4.1-mini に届くか, 2026. URL <https://github.com/auto-res2/scigym-rikyu-open-models>. commit 448f37a09a0b08100c7106ae09d7dfdb474c5372.

auto-res2/scigym-table1-reproduction (AIRAS). Scigym table 1 の事前登録再現: 現行 api の gemini 2.5 と gpt-4.1 で論文の平均 ste は戻るか, 2026. URL <https://github.com/auto-res2/scigym-table1-reproduction>. commit 4e9a531369741dd40e96224216012b4d29a91cb0.

Haonan Duan, Stephen Zhewen Lu, Caitlin Fiona Harrigan, Nishkrit Desai, Jiarui Lu, Michał Koziarski, Leonardo Cotta, and Chris J. Maddison. Measuring scientific capabilities of language models with a systems biology dry lab. *arXiv preprint arXiv:2507.02083 (NeurIPS 2025 Datasets and Benchmarks Track)*, 2025. URL <https://arxiv.org/pdf/2507.02083>.

h4duan. h4duan/scigym, 2025. URL <https://github.com/h4duan/SciGym>. commit 88a7b93609e35b6ecb4eb343d816d6ff09256c6a.